当前共享32KiB方案的后续优化评估

文档来源 commit：3812a069c22081fb0384677aa768a6f1f54be2b7

源文档 SHA-256：b048f4c1fbbda600a31db0d41d8a6bf28e6067d89389a19d114b98cdca6a845e

原文与链接：查看固定版本来源

口径说明：吞吐沿用旧体系的条件估计；RTL功能、局部实测、面积证据与整图条件结果分别报告。

Issue247 / PR243；负责人Melodydt。2026-11-10，Asia/Shanghai。三批服务器SystemC运行共192场景，生产RTL未修改。

结论：保持共享32KiB和17.1GB/s，向量8路 + S16桥接 + 4路NExp的prefill条件结果为4.423812/5.086834 token/s（shared/idealdual）。这是本轮优先建议。 桥接额外费用从1提高到8拍/8值，idealdual仍为5.057101。固定外存带宽的最高组合为5.508124 token/s，包含更多M/供数资源，面积代价更大。所有数值均为旧条件模型结果，原生RTL整图速度仍未测得。

1. 评价口径与当前实现边界

保留原四种工作负载：W8 decode context512、W16 decode context512、W8 decode context2048、W8 prefill2。频率300MHz、2P/1U，默认外存17.1GB/s、共享32KiB、每P四槽、共享A32B/拍、全局池服务64B/拍；保留原S32/K256/S96及R1/R2/R4调度合同。prefill2按两个输入token除以完整trace时间，不能与decode的单token延迟混用。

shared表示P本地读写共用服务预算；idealdual表示P本地各64B/拍读、写日历独立，U仍共用端口。当前P后端逻辑1R1W已验证，但M写回及普通IO仍128bit，独立wide_write才是512bit；不能把后端峰值当作整条访问路径已经兑现模型合同。

DDR25.6/34.2GB/s两行显式改变外存条件，其他行仍17.1GB/s。新计算/端口宽度和S16桥接只是待实现服务目标；没有新的RTL校准、完整权重生成验证或300MHz物理验收。现有真实RTL的格式转换、K32命令展开、DMA/LOAD汇合与队列费用仍须进一步校准。

2. 基线瓶颈证据

W8 decode512的idealdual基线中，Dot占完整trace时间82.27%，权重占外存总线字节96.17%；平均有效外存流量11.873GB/s。两通道总线忙占比分别68.98%/69.90%，并非全程100%占满；带宽敏感性仍证明外存服务是decode的重要限制。不能把可重叠的等待计数相加当作总耗时。

W8 prefill2的idealdual基线中，Dot占52.86%，向量阶段占31.52%，NExp占10.50%。36个NExp操作、792576个值全部是S16输入回退，原S32快路径没有覆盖它们。这说明优化U及格式覆盖比单独继续加MAC更直接。

3. 各方向方案、结果与实施含义

3.1 优先补齐S16 NExp快路径

保留4路NExp服务，只增加显式S16到既有低16位数值合同的打包桥接。模型每8值另收1拍，保留全部S读写、vector_region、缓存与DDR费用。prefill达到4.199320/4.792248 token/s，较同层基线+7.84%/+8.94%；三个decode不变。

继续增加到8路只到4.818940（idealdual），较4路桥接方案再提高0.56%。因此先做格式桥接和资格验证，再决定是否复制NExp单元。桥接的1拍/8值是假设目标，不能称为已测RTL延迟；必须检查符号、缩放、饱和、尾包和背压。

3.2 扩宽U向量流水

既有4路向量扩为8/16路，保留每包5拍固定开销及所有存储访问。prefill idealdual分别4.645880/4.780063，增幅5.61%/8.66%；W8 decode512的16路为3.865115（+4.46%）。只扩两处向量流水，未把归约、拷贝或整个U费用同比缩小。

16路向量与S16桥接4路NExp实际联合仿真得到4.545307/5.248140，相对基线+16.72%/+19.31%。没有扩共享容量，也没有增加M乘法并行度；作为性能优先的候选保留。

进一步测试较小的8路向量＋S16桥接组合，prefill为4.423812/5.086834（+13.60%/+15.64%）。桥接成本放宽到8拍/8值时仍为4.401308/5.057101。因此若以面积与达到条件5 token/s兼顾，先实施8路，再决定是否升到16路；这不是原生RTL吞吐保证。

3.3 M计算与A/B供数必须配套

单独将M主体的K并行8→16，保留启动、尾部及结果读回费用，本轮四场景两端口层均没有提速。单独将A32→64B、B适配64→128B也收益很小，因为本地S总读服务仍64B、池全局服务仍64B。

M16与A/B扩宽联合后，prefill idealdual为4.575113（+4.01%）。继续把M本地取数扩到128B仅到4.580113，较前者增0.109%。供数、存储、计算的收益不能相乘。

加入向量16路和S16桥接4路NExp的完整组合达到4.831646/5.508124；相对较小的向量＋S16方案，idealdual再增4.95%。需要更大面积及新端口组织，应保留为备选，不能优先假设单独加MAC就有效。

3.4 外存带宽主要帮助decode

总带宽17.1→25.6→34.2GB/s，W8 decode512 idealdual从3.700221→4.706094→5.404502，后者+46.06%；W16 decode512达到3.510143（+60.10%）。保留原两通道、信用、延迟、行切换及S服务，没有免费消除所有DMA成本。

prefill的idealdual仅升至4.910906（+11.64%），说明其U与计算限制更明显。外存接口、封装和控制器是否能提供该带宽须另行确认；这两行不是17.1GB/s下的优化结果。

3.5 共享池继续扩容

共享48/96KiB的prefill idealdual为4.475230/4.668451，较32KiB增加1.73%/6.13%。三个decode在48和96之间完全同速，不能期待容量不断翻倍产生同等收益。当前更建议保留32KiB，先实施格式与向量路径优化。

3.6 补齐M写回通路，收益须如实计量

旧模型已按64B/拍计M结果写入。把它收紧为实际普通写通路的16B/拍，prefill idealdual变成4.391319；从该修正对照补到64B恢复4.398913，增幅0.173%。W8 decode512对应增幅0.369%。这只是带宽敏感性，不含真实命令/ACK/打包成本；不能把已包含在旧基线里的64B收益重复添加。

3.7 NExp单纯加路数的负结果

仅将已合格S32路径从4路变8路，W8 decode512 idealdual从3.700221到3.712036；prefill完全不变，因为没有命中该格式路径。它应排在S16桥接之后，不能用局部两倍吞吐代替整图收益。

4. 面积与实施顺序

方向	面积/资源判断	建议
S16桥接 + 原4路NExp	增加打包、控制和有限缓存；没有要求增加NExp算术路数，具体面积未综合	第一优先，先做格式/数值/背压验证
向量8/16路	对所扩向量算术部分约2/4倍路数，不能等同整个U面积倍数	第二优先；优先8路 + S16桥接，16路保留余量
NExp8路	相对4路约增加一倍该算术通路，整图额外收益有限	暂缓
M16 + 宽供数 + 128B本地读	MAC主体约2倍K并行度，新增互连/端口/FIFO费用；不是已实现	大面积备选，实施前独立备份与综合
DDR25.6/34.2GB/s	控制器、接口和封装代价未测	decode目标且外部系统允许时优先
共享48KiB	比32KiB增加4颗4KiB宏，宏外框代理 +0.369848mm²	不优先于桥接/向量
共享96KiB	比32KiB增加16颗4KiB宏，宏外框代理 +1.479393mm²	保留为容量备选

宏代理使用既有4KiB宏0.092462050025mm²，只计宏外框，不含控制/布线/STA。128B读取若沿用同类宏并采用8lane×双位置，每P需要16宏、物理64KiB，相比当前8宏/P再增加32KiB/P；两P额外宏代理约1.479393mm²，逻辑16KiB可保留但需使用半深度。这只是一个组织选项，其他宏/端口方案需重新评估，不能作为已测面积或最小面积。

建议顺序：S16 NExp桥接验证 → U向量8路联合实现 → 原生整图/连续负载校准 → 视余量再升16路。若decode为首要目标且可调整系统，则推进外存带宽可行性；M/128B本地读和大容量共享池作为后续备选。当前分支和三个模型commit已保留全部方案；本轮没有实装这些新增候选。

5. 全场景速度表

单位均为条件token/s。每一行是独立实际SystemC运行或实际联合运行，不是Amdahl外推。write16为修正对照；其余默认比较共享32KiB、17.1GB/s基线，容量和外存变化按名称显式标出。

shared：读写共用日历

方案	W8 decode512	W16 decode512	W8 decode2048	W8 prefill2
当前条件基线	3.449322	1.932379	2.817071	3.894197
U向量8路	3.543265	1.961514	2.888617	4.086504
U向量16路	3.592181	1.976413	2.925771	4.189961
NExp 8路	3.459587	1.935597	2.844642	3.894197
M的K并行8→16	3.449322	1.932379	2.817071	3.894197
A64B + B128B适配	3.449331	1.932379	2.817076	3.899795
DDR 25.6GB/s	4.381208	2.362039	3.466442	4.575910
DDR 34.2GB/s	4.516442	2.486919	3.580178	4.669152
共享48KiB	3.474714	1.945252	2.833984	3.977429
共享96KiB	3.474714	1.945252	2.833984	4.189147
M写回16B修正对照	3.443988	1.930149	2.811324	3.888233
M16 + A/B扩宽	3.449331	1.932379	2.817076	3.917924
向量16 + NExp8	3.603315	1.979779	2.955523	4.189961
M16 + 供数 + 向量16 + NExp8	3.603324	1.979779	2.955529	4.217442
S16桥接 + NExp4路	3.449322	1.932379	2.817071	4.199320
S16桥接 + NExp8路	3.459587	1.935597	2.844642	4.219802
向量16 + S16桥接N4	3.592181	1.976413	2.925771	4.545307
M本地取数128B	3.527720	2.030034	2.880770	4.079372
M16 + 供数 + 本地取数128B	3.532406	2.031869	2.893090	4.102497
上述M组合 + 向量16 + S16桥接N4	3.682380	2.080611	3.007856	4.831646
向量8 + S16桥接N4	3.543265	1.961514	2.888617	4.423812
向量8 + S16桥接N4，桥接8拍	3.543265	1.961514	2.888617	4.401308

idealdual：独立读写日历

方案	W8 decode512	W16 decode512	W8 decode2048	W8 prefill2
当前条件基线	3.700221	2.192427	2.994659	4.398913
U向量8路	3.808541	2.230007	3.075640	4.645880
U向量16路	3.865115	2.249284	3.117796	4.780063
NExp 8路	3.712036	2.196570	3.025836	4.398913
M的K并行8→16	3.700221	2.192427	2.994659	4.398913
A64B + B128B适配	3.700233	2.192427	2.994667	4.429533
DDR 25.6GB/s	4.706094	2.968587	3.694922	4.807278
DDR 34.2GB/s	5.404502	3.510143	4.160466	4.910906
共享48KiB	3.711253	2.195909	3.001881	4.475230
共享96KiB	3.711253	2.195909	3.001881	4.668451
M写回16B修正对照	3.686626	2.188496	2.983256	4.391319
M16 + A/B扩宽	3.700233	2.192427	2.994667	4.575113
向量16 + NExp8	3.878008	2.253644	3.151604	4.780063
M16 + 供数 + 向量16 + NExp8	3.878021	2.253644	3.151613	4.988845
S16桥接 + NExp4路	3.700221	2.192427	2.994659	4.792248
S16桥接 + NExp8路	3.712036	2.196570	3.025836	4.818940
向量16 + S16桥接N4	3.865115	2.249284	3.117796	5.248140
M本地取数128B	3.701394	2.192436	2.995427	4.398913
M16 + 供数 + 本地取数128B	3.706661	2.194597	3.008810	4.580113
上述M组合 + 向量16 + S16桥接N4	3.872142	2.251568	3.133138	5.508124
向量8 + S16桥接N4	3.808541	2.230007	3.075640	5.086834
向量8 + S16桥接N4，桥接8拍	3.808541	2.230007	3.075640	5.057101

6. 验证、来源及复跑

run35/job102040（源码e2f91b346f57e872610b0e416290901f5d5e666e）、run36/job102041（源码d9afc95a9b649b096c8a7930d99d56d065d78047）和run37/job102043（源码f1700f031d629e5af33ad8b36ff9523a6393d90b）均在服务器c64/node1/4核Slurm中执行。三个作业均COMPLETED 0:0，合计192例通过；40次历史全RESULT控制一致，960个篡改结果负控拒绝。

实际生成的共享池A32/A64两设置合计4350个独立数值输出比较、60个生命周期负控和18个事件篡改检查通过；这仅验证共享池的地址/数据/FIFO模型，不是新NExp8/M16/S16桥接RTL数值验收。各例保持外存字节/描述符与M命令/tiles守恒，并核验逐类工作差额、有限队列和token换算。

本地逐SHA核验519个回收文件，并重新从逐例日志解析RESULT与主回执比对；完整事件和结果保存在个人服务器run35/run36/run37及本地receipts，仓库仅存轻量分析和索引。收集脚本初次因登录节点Python3.6不支持text参数失败，改用universal_newlines后成功；未重跑或修改已成功仿真。

run35 result SHA-256：2a5a21953b1be5f607d0c3ab1dd459415e9f29c215a7e4398410280c8f8e8f75；run36 result SHA-256：6ff313e48da5ec4ad4eb4ee6eab1702e7019615d09e1fa8282ff1260b651e70c；run37 result SHA-256：a465a266c485eeb30640f567e47cfbe3fa7c4602575d45a41e3a1164e081aa9d。工具版本及容器/SystemC库SHA见证据目录，所有输入版本沿用冻结manifest。

主扫描源码、补充扫描源码、桥接敏感性源码、完整派生比较与瓶颈、接续记录。

复跑必须在Slurm分配中，按各目录job.sh执行并携带冻结输入manifest。只做本地后处理时使用证据目录analyze.py，明确传入--runs-root与--repo；管理检查python scripts/check_project.py不代替业务仿真。

交付状态：研究结果待正式审查，PR243未合并，不标done；登记PR5 pending、看板unverified/同步pending，CI既有无steps/runner限制待管理员核实。没有活动仿真或自动监测。此前run24/25原包上传阻塞保留，本轮未重传旧包。