S16桥接与E流水化：实施、实测及后续取舍

文档来源 commit：dfd7a7932cf7e9934a17e3d1b5a167ed804f2a72

源文档 SHA-256：2b511102103528d6f1c4af0b30dfcf4ca22f617271d751c9d52a684484436b9d

原文与链接：查看固定版本来源

口径说明：吞吐沿用旧体系的条件估计；RTL功能、局部实测、面积证据与整图条件结果分别报告。

Issue247 / PR243；负责人 Melodydt；2026-11-10，Asia/Shanghai。沿用 task/242-r-load-bounds；本阶段是上一轮优化方向研究的具体落地，不重新计算此前已经结束的四轮迭代。

1. 结论与证据等级

S16输入到S32结果桥接已实现并通过原生RTL验证，适合优先推进受控集成。E算术核已实现可选4级流水，但完整U供数和调度仍串行：56项合法自然参数测试由988降到984拍，仅约+0.4065%。因此下一步的重点应是U的操作数缓冲和命令重叠，不应继续简单增加E算术通道。

原条件体系下，桥接局部费用校准后的prefill为4.216864 / 4.815109 token/s（shared / idealdual）。加入尚未闭合的完整U每拍8值服务目标后为4.443286 / 5.112600。后一列仍是候选目标，不能声称本版RTL已经超过5 token/s。

本阶段新增NEXP_S16和E_PIPELINE参数，默认均为0。没有启用参数的既有集成不会自动获得加速。共享池保持32KiB，A供数仍32B/拍，DDR仍17.1GB/s。本阶段未改SRAM容量、P数量或外存端口。

证据层次	已取得的证据	尚未取得的资格
原生RTL	真实S模型、完整U小负载、数值/ACK/背压/reset	整个大模型图的原生RTL运行
条件SystemC	原体系32例、8完整历史控制、局部实测费用	完整U每拍8值、真实端到端token/s
面积	同Nangate45库的4项标准单元映射	全U/全芯片面积、STA、布局布线

2. 对原建议的修正与瓶颈

检查现有RTL后确认：NExp已能处理8个packed S16，E也已经有8条S16算术通道。上一轮模型的vector_lanes=4/8是服务吞吐参数，不能等同于已有RTL的物理通道数量。S32数据每个128bit字只能容纳4个值；8条S16算术通道也不自动成为8条S32通道。

实际缺口有两处。第一，模型中部分S16 NExp的输出需要S32存储格式，原packed16结果不能直接作为该格式交付。第二，E核即使可以连续收数，compact接口依次提交A/B/C，U客户端还要读S、执行、写S、等ACK再接受下一条命令，无法持续喂满流水。

本次分别实现格式桥接和算术流水，再按完整U边界核验收益。没有用单核吞吐倍率直接乘原token/s。

3. S16到S32桥接的具体实现

修改pu_u_group.sv和ucf_s_compute_client.sv。仅NEXP_BATCH、NEXP_DIRECT、NEXP_S16同时启用时，开放op15/tag NX16（0x4e583136）。count为1至8，单个128bit源字包含packed signed16。尾部未使用输入置零，交给已有NExp计算路径。

每个U16结果零扩展为32bit。count不超过4时写一个128bit字；count为5至8时写连续两个字，每次都等待真实写响应。第二次写ACK之前不会给出完成。done_data返回低128bit，高半保存在S中。调用者需提供合法S16数据和原数值尺度；这不是任意S32数据的无损降位宽转换。

所有输入在写之前捕获，因此支持输入输出别名。非法count、来源数量、元数据和直接传递组合在S访问前拒绝。count大于4时禁止无存储输出，禁止目标地址1023导致第二字越界。原packed16和NX32协议保留。

reset会撤销旧完成事件，但若第一字已经写入，S中可能留下部分结果；两次写不具备事务原子性。上层必须重装所需数据并重发，不能把reset后的目标区当作完整新结果。

count	计算接受到done	下一次计算可接受	完整U接受到done	实际S读/写
1至4	6拍	7拍	16拍	1读＋1写
5至8	8拍	9拍	22拍	1读＋2写

完整U的16拍为输入5＋计算6＋输出5；22拍为5＋8＋9。后续模型对可重复服务计入退休1拍，所以采用计算费用7/9拍，以及完整U费用17/23拍。以上为本次小负载测试的观察边界，遇共享端口争用仍会增加等待。

4. E流水化的具体实现与收益边界

新增block_v2_e_pipeline.sv，block_v2_e_compact通过PIPELINED选择，pu_u_group通过E_PIPELINE选择。四级分别承担输入捕获、乘法/操作数对齐、算术组合、舍入饱和与输出。保持原14种合法操作的整数合同：加减、乘/FMA、最大最小、选择、移位、RoPE、RNE、绝对值和打包/窄化。

在A/B/C并行就绪且输出可接收的核心边界下，连续输入II=1，最多4项在途。输出背压时全流水冻结。非法操作14/15输出零与错误标记，功能合同保留，但错误响应延迟可与旧核不同。

核心测试（每段4096命令）	原核周期	流水核周期	流水核峰值在途
连续输入	15105	4100	4
间隙与背压	20608	7172	4

每段含3584条合法及512条非法命令；不能把混合命令总体倍率称作纯合法算子加速。独立Python整数oracle覆盖16编码×32种shift×8组数据，逐项比较结果、error和saturation；每段32768个值，两段共65536个值，每个配置再跑三组初始化/seed。

完整U采用同数据、同操作、同S路径比较，特意分开自然参数数量和合法的额外源读取，避免多读掩盖核心效果。

完整U工作集合	项数	原核总周期	流水核总周期	处理速度变化
合法操作，按需读源	56	988	984	+0.4065%
合法操作，额外读到3源	56	1128	1128	0%
非法编码，1源	8	56	80	-30%
非法编码，额外3源	8	120	120	0%

合法自然参数测试只有RoPE由20变19拍，其他操作相同。上一轮64项全额外源测试1248到1248也成立。以上是固定微负载总周期，不代表真实模型的算子频率分布；本次没有把0.4065%转换成整图提升。

5. 按原评价体系复评

统一条件为300MHz模型时钟、2P/1U、P私有S16KiB、共享池32KiB、A供数32B/拍、DDR合计17.1GB/s；使用原decode512/W8、decode512/W16、decode2048/W8和prefill2/W8输入。prefill2为原trace的两token场景，不能泛化为任意批量或上下文。

shared使用原P读写共享日历；idealdual允许原模型P读写独立日历。该差异不是DDR加倍，也不证明所有U/互连/DMA都已达到理想双端口吞吐。已有1R1W局部RTL证据不能自动授予完整系统idealdual资格。

四列含义：原基线完整RESULT复现历史run35；S16局部校准仅替换目标NExp计算包装层费用，保留原E/S/cache/DDR计费；完整U费用敏感性额外加入整帧17/23拍，与旧S费用存在重复计费，因此只是保守敏感性，不是严格实测下界；S16 + U8目标还假设完整U每拍8值，当前RTL未达到。

shared：token/s

原场景	原基线	S16局部校准	完整U费用敏感性	S16 + U8目标
W8 decode512	3.449322	3.449322	3.449322	3.543265
W16 decode512	1.932379	1.932379	1.932379	1.961514
W8 decode2048	2.817071	2.817071	2.817071	2.888617
W8 prefill2	3.894197	4.216864	4.176154	4.443286

idealdual：token/s

原场景	原基线	S16局部校准	完整U费用敏感性	S16 + U8目标
W8 decode512	3.700221	3.700221	3.700221	3.808541
W16 decode512	2.192427	2.192427	2.192427	2.230007
W8 decode2048	2.994659	2.994659	2.994659	3.075640
W8 prefill2	4.398913	4.815109	4.762102	5.112600

本次S16桥接只命中prefill2中的S16输入到S32输出NExp；三个decode trace该类操作计数为0，因此桥接列不改变decode速度。prefill局部校准相对原基线提高8.2858% / 9.4613%。加入完整U费用敏感性后仍约4.1762 / 4.7621，但不能把两列当作真实硬件置信区间。

上一轮4.423812 / 5.086834来自S16桥接 + vector8条件目标。本轮5.112600仅将相关S16费用替换为实测9拍/8值后的目标结果；它仍依赖未完成的U端到端吞吐。本版可诚实报告的是局部RTL功能/周期证据及条件模型数值，原生完整模型token/s仍未测得。

6. 面积开销

run43在同Nangate45库、同Yosys/ABC流程下映射4个模块；SRAM宏增量为0。只报告标准单元面积，不将寄存器映射面积当作物理SRAM面积。

局部模块	原面积（平方毫米）	新面积（平方毫米）	增量（平方毫米）
E算术核心	0.056905380	0.059758230	0.002852850

局部模块	原面积（平方毫米）	新面积（平方毫米）	增量（平方毫米）
N服务前端	0.004274088	0.005420548	0.001146460
已测两项合计	0.061179468	0.065178778	0.003999310

E核局部约+5.01%，两项已测合计约+6.54%。这不包含U连接逻辑变化、N计算核心、既有S、时钟树及布线，也不能推断全芯片百分比或300MHz可收敛。共享池既有面积仍按此前报告独立核算，不重复计入本轮增量。

修改前已备份task/247-before-s16-vector8到ddc12651e35035a25a206d2bdfe46d154864f2d8。两项新增能力默认关闭，可分别启用和回退。

7. 验证、版本与实验记录

最终原生run43/job102054，源码78c57285d206355cbcb5ae9f5cd51249964306cc；7配置×3组=21次运行，默认新旧U三组逐事件精确一致、桥接尾部/非法/别名/第二ACK/争用/reset、NExp全65536种S16输入对历史scalar路径一致、E独立oracle和完整U128项比较均通过。NExp测试证明与历史数值合同一致，不宣称相对浮点exp无误差。

原生校准run41/job102052，源码f5e8ce54884a45b1a816c7be238ba6f6d218d3c5。本次新增自然参数覆盖只改测试，run41和run43的生产RTL部署SHA逐文件相同。

模型run42/job102053，源码2d7aec50cbee93ad19d11a52b96459b194a45b5b。冻结run35生成源码/输入及原结果版本，使用run41实际profile；32例通过、8完整基线RESULT相同、160次篡改负控被拒绝。保留流量/M工作量、有限DDR队列、共享池容量/credit/生命周期和300MHz速率守恒检查。

三项成功作业均在yuzelu@10.129.166.172的个人目录/public/home/yuzelu/Melodydt/issue247-area-speed下运行，c64、node1、4核。run41用时1:30，run42为5:18，run43为1:32，均COMPLETED且退出码0:0。没有活动作业或自动监测。

工具：Verilator5.042、GCC11.4.0、SystemC3.0.2、Yosys0.63（70a11c6bf），ABC二进制、容器、Nangate45库及全部输入/生成物SHA见证据索引。209份回收文件逐项SHA及大小核验；另保留775份服务器结果文件索引（run41/43各346，run42为83），大型构建及网表留在个人实验目录。

结果回执	SHA-256
run41 result.json	413de7cbc6ad326bd88fc55b1f80ea3100c6cb974b1b636ddac16328999446d1
run42 result.json	59e272db682fff06f01d0f3ef170b9c93da24ca9d0a2d73338a366a8d1b017ec
run43 result.json	02b17d73ad1aeb90af2ec29ca1079eef1444628496b9b4823a8700e8be3675eb

失败尝试同样保留：run38/job102049因启动目录取错，run39/job102050因SHA清单CRLF，均在EDA前退出；run40/job102051因测试在实际写握手之前注入阻塞而死锁。修正测试为posedge真实握手后注入争用，没有删除第二ACK断言或修改RTL掩盖测试。后续run41/43均通过。

复现须先读远程规则，在新的获授权个人RUN目录部署对应源码、inputs.json及SHA清单，使用job.sh提交Slurm，不能在登录节点或本机运行EDA。原记录目录不覆盖。准确编译/运行argv保存在原result.json；回收与本地分析入口见交接及ARCHITECTURE。管理检查python scripts/check_project.py通过，仅代表管理结构。

8. 后续实施顺序与验收标准

第一步，审查并集成NEXP_S16桥接：调度端明确打NX16描述符，覆盖真实模型的量化尺度、尾部、两写地址和reset重试。先以真实NExp区域的完整U指令流替代现有局部费用校准，再判断整图增益。默认关闭状态不能直接算已部署能力。

第二步，重做U的供数与调度路径，再决定是否开启E_PIPELINE。候选做法是有限深度操作数FIFO、分离读/执行/写阶段、命令tag/scoreboard和输出缓冲；允许独立命令重叠，同时保留RAW/WAW依赖、写ACK完成、reset清空和有限credit。直接转发E到N或N到E可减少往返S，但必须携带格式/有效值数量和背压，不能绕过依赖管理。

带宽必须按实际位宽核算。例如8个S16二元操作每拍需要32B读＋16B写；8个S32二元操作则需64B读＋32B写。现有128bit单客户端路径与串行源提交不足以证明这些吞吐；只增加FIFO不能越过持续带宽上限。应先做有界队列和真实端口日历模型，再选择分bank、读写并发或旁路，避免先加面积后发现端口仍堵塞。

验收应以完整U持续合法负载为单位：同输出数/同数值合同、真实读写字节、有限峰值在途、背压/reset和依赖测试、端到端接受率；将实测服务反灌全部8个原场景，最后再做包含外围的面积和STA。5.1126目标的实现工作仍待此步骤，本阶段没有把新的U流式调度器冒称已完成。

9. 交付与待办

Issue247和PR243承载本任务；研究和实现提交审查，未合并/not done，审查人待指定。采用rayggxia-project-collab1.0.0；登记management-hub PR5仍pending，缺board配置与Projects工具，看板状态unverified、同步pending，待管理员处理。

源码78c57285上的GitHub结构CI run42841550005为failure，validate没有可用steps/logs，具体原因待管理员核实。没有绕过检查。完整原生大模型、全U面积、STA和物理实现均未执行；本轮未修改ref-project，也没有重传旧run24/25受阻原包。

详细复核数据见分析与索引，恢复执行见交接。