S32 向量路径：实施、速度校准与面积评估

文档来源 commit：72ce19af3fd1a21dd19f1197bd5a3e34e1f08219

源文档 SHA-256：15855f26c7fa32a27d1070537e911dc065f7102dd427468823d7e31b579f878b

原文与链接：查看固定版本来源

口径说明：吞吐沿用旧体系的条件估计；RTL功能、局部实测、面积证据与整图条件结果分别报告。

2026-11-11，Asia/Shanghai；负责人 Melodydt；Issue247 / PR243。本轮落实上一阶段第一项建议：补齐原图 S32 E 子集，再把两槽队列的真实收益纳入原评价体系。生产配置默认关闭，交付待审查，未合并。

1. 本轮结论

已增加四通道原生 signed32 E 核，接入串行/两槽/四槽前端。计算使用完整乘积和宽中间值，支持 signed7 位移量，末端统一饱和到 S32。原图中 shift=34/35 及负 shift 不再依赖截断后的 5 位字段；S32 数据也不截短为 S16。

真实 U 后端下，64 个 S32 值的一输入算子由 208 拍降为两槽 138 拍，吞吐提升 50.72%；二输入算子由 288 拍降为 198 拍，提升 45.45%。四槽分别为 131/198 拍，二输入没有额外收益。测量包含真实 S 读写、计算、写 ACK 与完成退休。

沿用原 8 场景，S32 两槽相对同口径串行的 prefill 提升 16.38%（shared）和 17.94%（idealdual）。两槽 prefill 为 2.940530/3.219458 token/s；四槽再提高 0.11%/0.12%。这是局部实测校准后的条件模型，不是完整模型 RTL 实测。

新数字可能低于上轮 4.184811/4.773362：这次把原先理想化的 S32 本地服务替换为完整 U 实测期，校准范围发生了变化。旧配置本身没有变慢，8 个完整历史控制全部复现。不能将局部队列加速倍率直接乘到整图，也不能把历史条件估计当作硬件已达到的速度。

2. 出发点：先解决原图位宽，再讨论扩宽

上一阶段队列主要测了 S16 算术，但三个原 trace 中可以直接按纯 S16 E 处理的算子为 0。原图有 S32 乘法、转换、加减和最大/最小；prefill 还有超过 31 的右移和负向左移。仅把 8 个 S16 通道当成 8 个 S32 通道，会同时误算精度、端口字节数和速度。

本轮选择先在既有 128bit 数据口放四个 S32 值，验证足够宽的数值合同和有限队列，再测瓶颈。保留共享池 32KiB、A32B/拍、DDR17.1GB/s、2P/1U 以及实际原本地 S 仲裁器，没有扩容或虚构每拍一个事务。

按位宽、元数、移位和等形状筛选：decode512/decode2048 各 108 个算子、543744 个值；prefill2 为 1909 个算子、24228352 个值。仅匹配一输入 Convert 或二输入 Add/Sub/Product/Maximum/Minimum，全部输入输出 S32，元素数为 4 的倍数，无广播。混合位宽、多输入、广播、未支持的 canonical 算子继续保留旧模型费用。

该筛选只是形状和算术合同的候选映射。trace 不含完整真实激活值和量化尺度；本轮不能证明完整模型精度，也未生成混合 S16/S32 图调度器。

3. RTL 方案与具体做法

3.1 数据通路与数值合同

新增 `block_v2_e_s32.sv`，每个 128bit 向量字含四个有符号 32 位 lane。乘法先得到 64 位积，FMA/RoPE 的合并中间量使用 65 位，舍入/移位使用 96 位；不在最终输出前截窄。核心采用两步执行：输入接受时锁存算术中间量，随后舍入、饱和并保持输出，等待 out_ready。它不是 II=1 的 S32 流水核。

opcode	操作	shift 合同
0/1	加/减	忽略 shift
2/3	乘/乘加	正数 RNE 右移，负数饱和左移
4/5/6	最大/最小/按 C 非零选择 A	忽略 shift
7/8	饱和左移/算术右移	只接受非负 shift
9/10	成对 RoPE/重定标	正数 RNE 右移，负数饱和左移
11	绝对值	INT32_MIN 最终饱和
12..15	本 ABI 不支持	返回 error，不写 S

RNE 为最近值、恰好中点取偶数；负数先按向下取整商和非负余数判定。shift 范围 -64..63。左移量达到 32 且值非零时直接判饱和方向，避免有限宽移位溢出后符号翻转。out_saturated 表示至少一个 lane 最终越界；非法指令返回 error。RoPE/FMA 合同只保证本 ABI，未声称与整图多算子中间饱和完全等价。

3.2 与现有 U、有限队列连接

`pu_u_group` 增加 E_S32 参数，默认 0；`block_v2_e_compact` 增加 S32 参数；串行及队列服务增加 SHIFT_WIDTH 参数，默认 5，S32 时为 7。只在选择 S32 的 U 实例改变 shift 接口宽度，默认 S16 路径保留原行为。E_S32 分支优先于 E_PIPELINE，不能把旧 S16 的流水开关当作 S32 II=1。

建议后续集成选择 E_S32=1、E_QUEUE_DEPTH=2。队列沿用按序读/发射/写回、RAW 等待写 ACK、WAR/WAW 保序及有限占用；没有新增跨客户端一致性。direct-A/abort、错误不写回、done 背压和 reset 合同保持。reset 清控制状态，已完成的 SRAM 写不回滚。

这是静态配置的 S32 实例，尚无运行时 S16/S32 混合分发、S16 输出 packing 或广播 lowering。部署完整图仍须补这些环节。共享容量和原 S 仲裁未变；备份分支 `task/247-before-s32-vector` 固定在 e22e60c6868795fb0f2e708c7e21358ce19a8b03，已在线读回。

4. 原生测试与周期结果

run49/job102642，c96/node15/4核，COMPLETED 0:0。共 186 次运行：旧参考/默认/两槽 S16 各 9 例×3，S32 深度 0/2/4 各 11 例×3，NExp 两种格式各 3 次。冻结旧 U 与默认配置的 27 对周期、流量、结果及覆盖观测完全一致。

Python 任意精度整数 oracle 与 RTL 独立实现；seed=2474701，含 S32 极值、正负舍入中点、所有 16 opcode×128 移位组合、相关/别名、direct/abort、IO 争用、完成背压及三个 reset 时点。每次运行检查每条命令的结果/error/saturation、读写数、写 ACK 先于完成、队列容量和全部 1024 个存储字。构造数据通过不等于真实激活推理质量通过。

下表固定同一 SRAM 后端和 S32 核。前四项各 64 条命令；mixed_edges 为 2048 条；hazards/direct 为 128 条；最后两个 tile 各 16 条，即 64 值。不同负载不能横向比较速度。

负载	串行	两槽	四槽
unary_s32	832	546	515
binary_s32	1152	774	774
product_s32	1152	774	774

负载	串行	两槽	四槽
convert_s32	832	546	515
mixed_edges	29024	19190	18149
hazards	2524	2115	2115
direct	1834	1076	901
backpressure	1207	918	774
io_contention	2114	2114	2114
unary_tile	208	138	131
binary_tile	288	198	198

两槽/四槽二输入 tile 都需 32 次读、16 次写和 16 次写 ACK，总计 48 次 S 事务，198 拍约为 4.125 拍/事务。四槽一输入 32 事务用 131 拍，约 4.094 拍/事务。这是完整服务比例，不能误写为 SRAM 宏延迟。现有仲裁采用 IDLE/SEND/RETURN 且仅容许一条在途事务，是接下来优先修改的协议瓶颈。

run47 在 sbatch 阶段因 DOS 换行被拒绝，没有作业号；修正 job.sh 为 LF 后使用新目录 run48。run48/job102637 的 168 次回归和 8 项面积也全部通过；run49 在相同生产 RTL 上补 64 值 tile 用例，全量重跑为 186 次。历史目录和 SHA 均保留。

5. 原评价体系的各场景结果

固定 300MHz 条件频率、2P/1U、P/U 私有容量基线、共享池 32KiB、A32、DDR17.1GB/s。shared 与 idealdual 含义沿用原模型：idealdual 是 P 读写端口条件场景，本轮 U 在两列都使用同一真实单事务服务测量，不能把它解释为所有实际 SRAM 都具备理想双端口吞吐。

单位 token/s。旧条件列是上轮完整 RESULT 重新复现；S32 三列使用同一新增校准范围，彼此才是本轮队列收益的直接比较。

场景	上轮条件复现	S32串行校准	S32两槽校准	S32四槽校准
W8 decode512 shared	3.449322	3.365489	3.394608	3.394608
W8 decode512 idealdual	3.700221	3.603919	3.637330	3.637330
W16 decode512 shared	1.932379	1.905784	1.915087	1.915087
W16 decode512 idealdual	2.192427	2.158256	2.170194	2.170194
W8 decode2048 shared	2.817071	2.760903	2.780469	2.780469
W8 decode2048 idealdual	2.994659	2.931267	2.953331	2.953331
W8 prefill2 shared	4.184811	2.526565	2.940530	2.943791
W8 prefill2 idealdual	4.773362	2.729773	3.219458	3.223368

模型冻结 run46 生成源码，8 个历史 RESULT 完全一致；32 次 SystemC 运行及 160 个篡改负控通过。每个可匹配 64 值 tile 保留原 cache/DDR 访问顺序，移除旧向量计算费与本地 S 读写费，改为一次实际 U 服务期。两槽一/二输入为 138/198 拍，不能再叠加理想 E pipeline 加速。不足 64 值但仍为 4 的倍数时保守按完整 tile 计费。

prefill 两槽校准覆盖 1909 个算子、378640 个 tile、24228352 个值，其中不满 64 值 tile 为 144 个；移除旧 E 费用 7950288 拍，新增包含 S/ACK 的完整 U 费用 73033200 拍。旧本地 S 费用单独移除，精确 subcycle ledger 见证据。

检查保持 DDR 读写字节、描述符、M 工作量、cache 事件完全一致；同时验证有限 32 credits、共享池峰值和生命周期、向量工作守恒、token/s 算式和原 trace 覆盖。该模型仍保留未匹配算子的条件假设，未包含完整混合图 dispatcher 的实际开销，因此不声明全图 RTL 校准。

历史 4.773362 是较窄校准范围的 prefill idealdual 条件值；更早 5.112600 还额外假设完整 U8 服务。本轮并未证明任何已部署完整 RTL 模型达到 5 token/s。

6. 面积及取舍

Nangate45 同库 Yosys/ABC 标准单元映射；库 SHA 及工具版本见证据。所有 8 项映射完成，没有未映射单元。仅比较本地 E 核/前端/序列器，未包含 SRAM 宏、S 仲裁、N 核、U 胶合逻辑、时钟树及布线；没有 STA/P&R 或 300MHz 物理验收。

模块	标准单元 μm²	说明
旧 E 核	56905.380	S16 基准
S32 E 核	84061.852	本轮四 lane、宽中间量
旧串行前端	2473.002	shift5
旧两槽前端	9386.342	shift5
S32 两槽前端	9381.288	shift7
旧四槽前端	18350.542	shift5，不能当 S32 四槽精确面积
旧可选流水 E	59758.230	独立比较项
NExp 区域序列器	882.056	前阶段已有

S32 核比旧核增加 0.027156472 mm²（+47.72%）。S32 两槽“核＋前端”相比旧 S16 两槽增加 0.027151418 mm²；相比旧 S16 串行增加 0.034064758 mm²。这些不是全 U/芯片涨幅。前端 shift7 映射面积略小是综合优化结果，不能据几个门的差异推断物理优势。

新增 SRAM 宏为 0。四槽二输入无收益、一输入只再改善 5.34%，不值得在本阶段默认采用更深队列。新 S32 核不是免费优化，但它补上原图位宽支撑；维持默认关闭及备份，等待完整调度与面积/时序审查。

7. 下一步具体实施顺序

优先推进 U 本地 S 连续请求协议：在有限请求/响应队列下分离请求接受与响应返回，保证返回路由、读后写/写后读顺序、写 ACK 和 reset；与当前单在途模式做默认逐项对照。先在两槽 S32 上验证每拍请求条件及实际 SRAM 接受能力，再考虑 1R1W，不把端口宽度直接等同吞吐。

随后补混合位宽调度与明确的 Convert packing、广播和多输入 lowering，用真实图中可重放的数据验证。只有具备实际激活/尺度及逐算子一致性证据后，才能扩大校准范围和部署完整模型。

S32 lane 扩到 8/16、更多 M、48/96KiB 共享池和外存提速继续保留为独立方向；本轮结果显示单纯把队列加深到 4 槽已难以改善二输入服务，应先消除本地 S 事务气泡。

8. 版本、复现及交付状态

运行	源码 commit	作业与状态
run48 原生/面积	532745f61ddf28af3c722daa99a5621f49e7a43c	102637，COMPLETED 0:0
run49 正式原生/面积	a49537ee55dae2003c19fa3d44b5817f9d616db8	102642，COMPLETED 0:0
run50 原体系模型	68ed552f6291e2d5023ac032e6607ed56aae3222	102656，COMPLETED 0:0

服务器 yuzelu@10.129.166.172，根目录 `/public/home/yuzelu/Melodydt/issue247-area-speed`；run48/49 为 c96/node15/4核，run50 为 c64/node10/4核。各目录 source/ 保存锁定源码，slurm-作业号.log 为启动日志，results/result.json 为结果。实际启动命令在各根目录执行 sbatch --parsable job.sh；脚本通过 srun 和固定容器运行。

```
cd /public/home/yuzelu/Melodydt/issue247-area-speed/run50
squeue -j 102656
sacct -j 102656 -X --format=JobID,State,ExitCode,Elapsed,NodeList
tail -n 30 slurm-102656.log
cat results/result.json
```

原生入口 project/experiments/s32_vector_native/run.py；模型入口 project/experiments/s32_vector_model/run.py；复核入口同目录 analyze.py。每次新建目录，固定 source/input SHA 清单，不覆盖结果。run49 和 run50 的 371 份回收文件 SHA、原生 summary、模型日志 RESULT 均重新核验。

原生 result SHA：0e0d499eb5eddc29cd5cc68da17f644768c898782970c6a3774fe24641633f56。模型 result SHA：9898c1a7181180a3cc00574cf440d078876bad00a9b51f2e29ade6891ea8a742。模型输入 run46 result SHA 固定为 4be10c512c8d28e7e41eaaedab4a4f6803adbc4450458f0ec59f33c49b20c1cc。所有原始构建、全日志、网表留在服务器，以 output-files.sha256 索引；仓库提交有界回执，详见证据索引和分析。

python scripts/check_project.py 管理结构检查通过，不能替代功能验收。源码 CI42953113735 completed/failure，validate 返回 steps/logs=null，原因待管理员核实，未绕过检查。正式审查人待指定；PR 未合并，Issue 保持 in_review，不标 done。登记 management-hub PR5 open/unmerged，pending；无 board 配置及 Projects 工具，看板 unverified、同步 pending，处理人待指定。遵守 rayggxia-project-collab 1.0.0；全部本轮作业已结束，没有自动监测。恢复从交接开始。