第二轮：单命令且保持状态的NExp

文档来源 commit：e531a9944ff1ae4bc55e3b6e204be48f425af1a3

源文档 SHA-256：6eb44da984bc5302850a82b7d946a474992918a4037fde59ada4bca983e8d562

原文与链接：查看固定版本来源

口径说明：吞吐沿用旧体系的条件估计；RTL功能、局部实测、面积证据与整图条件结果分别报告。

Issue247 / PR243；负责人Melodydt；2026-11-10，Asia/Shanghai。本轮在第一轮已通过版本上继续优化。实际RTL与旧体系16场景评估均通过；主条件吞吐3.66958239533 token/s，未到5。本文完整转换为PDF，排版核验另存，不以PDF替代机器证据。

1. 瓶颈与本轮选择

第一轮主W8 decode512、ctx8、16KiB、理想端口参考耗时274.968172667ms，吞吐3.63678454238 token/s。其中Dot224.101536667ms，占81.50%；NExp7.427983333ms。NExp已使用同一个原生N核批处理，但每包仍执行清状态、统计零输入、结束统计、指数回放四条内部命令。其四元素NX32服务为19拍，而且会破坏普通N的统计会话。

本轮选择消除这些重复的状态初始化和命令往返：对相同相对指数数值增加原生单命令入口，复用原两条指数计算通道和查表函数。它是面积较小、数值合同明确的一步，不声称能够解决占比最大的Dot。下一轮转向矩阵供数；本轮先用完整回归把共享N的新状态语义验证清楚。

主比较维持旧PR241/Issue247的300MHz、2P/1U、17.1GB/s、S32/S96条件模型及原trace。共享端口与理想1R1W分列；当前四个1RW bank不因此获得理想端口资格。SRAM每block仍16KiB。W16、长上下文和prefill也运行，不能用较高prefill吞吐替代decode停止条件。

2. 数值与接口合同

旧标量参考计算固定点函数exp(x-max(x,0))，第一轮用截断后的min(x,0)与零最大值批处理。第二轮原生op12直接调用同一个exponential函数；该函数对非负输入返回32768，所以直接相对指数与旧参考逐值相同。这是原表的整数编码合同，不是通用浮点exp。

原生op12仅在NEXP_DIRECT非零时合法，count为1到8，param与aux必须为零，未使用的完整S16 lane必须为零。参数默认0；默认版本仍将op12视为非法。生产U内还要求NEXP_BATCH同时非零，避免只开启DIRECT就意外扩大普通N的命令集合。

外部U仍使用第一轮op15描述符。PACKED16魔数0x4E455850对应最多8个S16；NX32魔数0x4E583332对应最多4个S32容器，使用每个容器有符号低16位，结果U16零扩展到S32。已用容器高16位按既有合同忽略；未用容器必须全零。NX32不是任意S32指数计算，也不是无损S32转换。

旧评估中仅S32输入、S32输出的NExp合格。prefill的S16输入、S32输出不符合这一包宽合同，保留原完整路径和费用；没有把单个128bit输出冒充256bit结果。

3. RTL具体实现

文件	本轮修改	默认及资源边界
block_v2_n.sv	增加可选op12检查与执行分支；复用CALC/ACCUM、原指数函数和结果寄存器	NEXP_DIRECT=0；仍两lane
nexp_batch_adapter.sv	DIRECT1只发一次op12，收到响应即可完成；DIRECT0保持四命令	不复制N，不增加数据寄存器
pu_nexp_shared.sv	传递参数，保持所有权、描述符和NX32打包规则	响应退休前不交叉使用N
pu_u_group.sv	由BATCH与DIRECT共同使能新原生命令	两参数默认0；原S客户端保留

上述前三个U辅助文件位于project/rtl/pu_leaf_base；原N位于project/rtl/block_v2。完整源差异、冻结基线和生成器在project/experiments/rtl_iterations/round2；旧模型接入在project/experiments/iterative_speed/round02。第一轮目录保持冻结，第二轮实际生产源必须与生成候选逐字节相同才能启动测试。

```
U op15 -> 描述符检查 -> 原S读客户端
       -> pu_nexp_shared持有唯一N
       -> DIRECT0: op0 -> op1 -> op2 -> op3
       -> DIRECT1: op12 -> 原两lane指数计算
       -> 原S写请求 -> 真实写ACK -> U完成响应
```

原ACCUM中exp_sum和exp_count的更新改为仅operation==3时执行。op12更新临时operand、position、result及响应状态，不修改maximum/count、factor、exp统计、replay游标或top状态。原命令0到11的功能和普通事务相对周期通过对照；DIRECT0完整批处理时序也通过精确回归。

DIRECT1可以插入普通N会话并在结束后继续该会话；DIRECT0仍保持第一轮显式clobber语义，使用者须重新op0。非法请求在准入处拒绝，错误不写目的S；held response期间所有权保留，不能用done有效代替写回完成。复位清除在途事务，旧响应不得在新会话中泄漏。

4. 面积、频率与备份

相对第一轮，本轮没有新增寄存器声明、乘法器、EXP lane、LUT或SRAM。新增的是opcode判定、输入选择和持久状态写使能条件。第一轮约402bit显式状态仍保留；不能据此断言综合面积完全不变，新增选择逻辑也可能影响时序。

综合面积、STA、布局布线和功耗均未执行。300MHz是固定旧模型比较条件，不是本轮新RTL的物理资格。此次没有复制完整计算资源，不属于巨大面积候选；初始完整备份task/247-speed-base-a22e199c及第一轮不可变源码归档均保留。下一轮若增加矩阵资源，将另行备份并列出数量账本。

5. 服务器RTL验证及实际周期

run18 / Slurm101852 / mdt-r2-nexp-rtl，c64/node1/4核，2分37秒，COMPLETED 0:0。源码863492081f0f512fc64fb73c787fcdcaf145a6b4。Python3.10.12、Verilator5.042、GCC11.4.0；容器和真实SRAM模型SHA固定并记录。36源文件、1份run16原始输入绑定。13个版本逐个编译，每个使用三种初始化/seed配置1:143、2:143、2:144。

每个compute seed检查66,524个值、8,588帧，包含全部65,536个S16输入；实际新路径观察到8,608个op12、零条其他内部命令。每个fullU seed有661项检查、409次S读与43次S写，验证真实SRAM路径、错误哨兵、背压和复位。每个

stateless seed覆盖12种上下文状态、102项检查和12个复位时点，包含统计、factor、replay及top的持久快照和后续合法执行。

参数组合四种均测试；新默认对旧默认完整COMPAT事件精确一致。BATCH1/DIRECT0对第一轮BATCH1的完整批处理、计算及S事件精确一致。BATCH1/DIRECT1普通N事务的接受至响应间隔、元数据和结果保持一致。新router独立严格lint通过，原有完整模块警告策略保留，没有删除检查来通过测试。

NX32元素数	第一轮计算接受至可再接受	第二轮计算接受至可再接受	第二轮完整U接受至DONE
1、2	15拍	7拍	16拍=5输入+6计算+5输出
3、4	19拍	9拍	18拍=5输入+8计算+5输出
5、6	34拍，拆4+1/2	16拍，拆4+1/2	两个真实NX32事务，未省略S阶段
7、8	38拍，拆4+3/4	18拍，拆4+3/4	两个真实NX32事务，未省略S阶段

三个seed的实际费用相同。模型采用计算包装器接受至可再接受的费用表[7,7,9,9,16,16,18,18]；完整U费用另列，不能把它再次加到已保留的旧vector_region上。计时在DONE首次出现处结束，后续人为保持响应不进入无阻塞headline；背压仍有独立功能检查。

6. 旧评价体系接入与防止重复收益

模型只替换原NExp在vector_region之后额外收费的计算服务。原E费用、S读写、cache、DDR、M、上下文和预取策略均保留。两个费用账本只用于主机侧比较，实际只收取被选择的那一个，不复制N资源。

第二轮开关关闭且R1开启时，移除唯一新增iteration2_study元数据后，完整RESULT必须等于run17相应候选。第二轮开启时iteration_study记录实际新profile身份、费用及来源，不能把新费用伪装成旧profile。没有合格输入的prefill完整回退，结果仍与run17相同。

run19 / Slurm101854 / mdt-iter2-nexp，c64/node1/4核，2分53秒，COMPLETED 0:0。同源码commit；70源文件、12输入绑定，SystemC3.0.2。共16场景，8个基线完整复现第一轮；冻结R1生成源码SHA精确复现。每场景8项结果篡改拒绝，共128项；8种profile负例、3种非法CLI、R1关闭以及缺失新profile均拒绝。原225 kernel、4 validation、5 smoke通过。

新校准必须绑定实际退出0的命令、日志SHA、seed以及op12路径观察，同时要求状态保持和旧批处理兼容两项新增门。费用不可由预计周期填入，缺门或来源不匹配即拒绝。

7. 实际吞吐与增量

场景	R1共享口	R2共享口	R1理想端口	R2理想端口
W8 decode512	3.35052563236	3.37834376557	3.63678454238	3.66958239533
W16 decode512	1.87361334071	1.88228047460	2.16739415621	2.17900079544
W8 decode2048	2.68546727945	2.75828381390	2.87778676255	2.96156894073
W8 prefill2	3.10725416366	3.10725416366	3.69669737899	3.69669737899

单位均为token/s，属于旧体系条件整图估计，不是完整原生RTL执行大模型生成的实测速率。主场景本轮共享提升0.8303%、理想提升0.9018%。与新迭代起点相比累计共享约4.57%、理想约4.96%；逐轮比例不能直接相加。长上下文收益更大，prefill明确为零增益。

主场景36个NExp合计294,912元素、36,864个八元素计费帧。补充费用由第一轮1,400,832拍降为663,552拍，减少737,280拍，即2.4576ms。理想端口总耗时由274.968172667ms降为272.510572667ms；共享由298.460632667ms降为296.003032667ms。context2048减少9.8304ms。流量和M工作保持不变，不能把局部19到9拍的比例乘到整网吞吐。

8. 追溯与复跑

源码、输入、工具、输出与归档SHA索引位于迭代证据。源码commit和本文/PDF文档commit分别记录，不能把后续文档head当作已运行源码。两个服务器目录为/public/home/yuzelu/Melodydt/issue247-area-speed/run18和run19，登录yuzelu@10.129.166.172；source/、slurm-job.log和results/持久保存。

证据	SHA-256
run18 payload	4e31d17528f82e57e5a80465b2d7e399f39a80f91b4b740dda3d2055f0f46bd5
run18 result	fb0b4d0d1251140655feea5bd671c196e5ae13b1fd47066dc22d6e1e1a2eac78
run19 payload	5de12dac86a38cafda9562f9278546173b50c111a7ae29bec6fe8927ec6011fe
run19 result	b16ff9a0209add1227177d1899bbf9928ae7e83d724a0c113469e7c860c97098

run18全部708输出哈希、69份选中结果SHA核验；run19全部96输出哈希、70份选中结果SHA核验。编译对象和二进制留服务器，仓库保留可验证源码快照、日志、原始结果及索引。离线核验运行python work/Melodydt/247/speed-iterations/verify.py；管理结构另运行python scripts/check_project.py，后者不能替代业务测试。

```
sacct -j 101852,101854 -X --format=JobID,State,ExitCode,Elapsed,NodeList
cd /public/home/yuzelu/Melodydt/issue247-area-speed/run19
tail -n 60 slurm-101854.log
cat results/result.json
# 新目录内按已归档job.sh提交；不要覆盖既有run18/run19结果
```

9. 结论与第三轮取舍

保留第二轮作为当前最快候选；新增参数仍默认关闭。主条件速度3.66958239533，未达到5；还需继续迭代。Dot仍为224.101536667ms，现占主条件总时间约82.24%。下一轮优先验证S32/S96矩阵候选与真实有限供数衔接，而不是继续假设计算核II等于整个P服务周期。

第三轮需明确有限缓冲、同上下文K依赖、实际四bank端口占用、输入响应信用、最终写ACK及资源代价。相同旧模型下若候选退化，保留负结果并保持已有最快配置；不能弱化基线或忽略新增数据搬运来制造收益。SiLU41、RoPE3和Reciprocal128尚缺完整微程序和逐步舍入合同，暂不凭缩小费用系数宣称等价提速。

本任务继续in_progress；迭代完成数量以PDF逐页核验及上传后的总入口为准。PR待独立审查、未合并；登记management-hub PR5 pending，缺Projects配置/能力，看板unverified、同步pending。完整模型生成、量化质量、面积、时序、物理验证及线上CI资格仍分别验收，没有聊天结束后自动监测。