第三轮：矩阵核的有限供数与双缓冲

文档来源 commit：809f9820cc13157077e4399a789779aac52925db

源文档 SHA-256：3d4ac074900989566713f0ef3f3276fcbde6eebf6056eaceccb0ad43571cd72f

原文与链接：查看固定版本来源

口径说明：吞吐沿用旧体系的条件估计；RTL功能、局部实测、面积证据与整图条件结果分别报告。

Issue247 / PR243；Melodydt；2026-11-10，Asia/Shanghai。本轮从第二轮的矩阵瓶颈出发，实现并校准独立的S32/W8/S96矩阵候选，然后在原评价体系中比较关闭、单缓冲和双缓冲。末节给出真实整图结果及下一轮选择。本文全部内容转换为PDF；机器证据与视觉QA独立保留。

1. 出发点与可检验假设

第二轮主W8 decode512条件耗时272.510572667ms，吞吐3.66958239533 token/s；Dot占224.101536667ms，即82.2359%。单独继续优化NExp只能影响较小部分。PR241已有较宽K16矩阵叶核，但叶核的流水接受率不等于整个P的服务速度：输入必须从真实S读取，部分和有依赖，最终结果必须写回并确认。

本轮假设是：增加有限输入寄存器，把下一包的S读取与当前包计算重叠，有机会缩短矩阵服务。先实现真正的有限资源和握手，再测量；不使用理想的无限FIFO或把叶核II直接换成整块费用。单缓冲作为同一实现的对照，双缓冲只增加一个输入包槽。

固定比较条件为旧PR241/Issue247的S32/S96模型、300MHz、2P/1U、17.1GB/s、每block 16KiB、8组上下文、原输入trace和预取策略。共享口和理想1R1W两层分别报告。实际四1RW宏不具有模型理想端口资格；本轮没有扩容SRAM。停止条件仅看W8 decode512主项，不能改用prefill或W4。

2. RTL数据路径和资源

独立目录project/experiments/rtl_iterations/round3包含r3_m_finite供数包装、复用的K16/N8/ROWS8算术叶核、真实S包装、数值测试、控制重放和运行器。原生产P16、R1及R2生产实现保持原有版本。候选是可执行RTL实验，还没有完成原生P/DMA的全部接口集成。

```
命令检查 -> 8项完成预约与context租约
         -> 1或2个有限包槽 -> A/B真实S读 -> 原K16叶核
         -> 每次提交更新S96 -> 最后包产生S32结果
         -> 2次128bit S写及ACK -> 完成退休 -> 释放context
```

每包最多16个K、8个N。A为64B对齐，读取一条64B；B保持原K-major按N排列的字节顺序，可跨1到3条64B线，192B gather暂存，不要求免费的外部转置。每个包槽有64B A和192B B，共256B数据。主资格N8/K16时B实际读取128B，每包真实读取192B。

S仍是四个256×128的1RW bank，共16KiB。包装接受512bit宽读和128bit窄写；同一拍读写至多接受一个。读响应metadata只有2条，最终写状态机只有一个，完成预约固定8条。单、双缓冲使用同一FSM和同一算术资源；槽在叶核真实接受输入时释放，允许同边复用，不人为延迟单缓冲。

输出占用16B对齐的32B独占区。即便N尾部较短，也执行两次128bit写入；DONE与context释放必须等两次真实ACK，不能在结果valid时提前宣布完成。输入和输出的别名、越界、对齐与重复使用均在准入检查。

3. 上下文和错误合同

描述符包含ctx、tag、K偏移、总K、当前K/N、shift、FIRST/LAST及A/B/output地址。reserved_nextK在合法命令接受时前移，使同一context能够有限预取；committed_nextK只在叶核真实第三个推进边沿提交时前移。提交与下一输入同拍时使用明确旁路，不将尚未计算的数据标为已提交。

FIRST不得覆盖仍存活的context。后续包须匹配tag、K连续性、N、shift和output；LAST关闭新的输入租约，直到两次写ACK且对应完成被消费后才释放。即使新FIRST的形状和tag本身合法，旧final尚未退休时仍必须拒绝。错误命令占用一个有序完成预约，但不读S、不送叶核、不改变累计结果。

输出背压保留数据和标签，控制不得因ready拉低而重复接受或丢失完成。全组复位清除在途包、读metadata、context及完成队列；复位后不得出现上一次事务的写入或响应。本轮在20个复位时点和不同背压阶段验证这些合同。外部DMA覆写输入的完整联合租约合同仍待接入，不能把局部保护称为全系统一致性。

4. 面积账本与额外备份

候选叶核含128个有符号32×9乘法器、8棵16输入归约树，以及8组×8列×96bit部分和。这个算术规模属于需要额外备份的面积候选。寄存器声明账本如下；组合算术、选择网络、布线和宏外围没有计入。

项目	单缓冲	双缓冲	增量
包装器显式状态	3836bit	5994bit	2158bit
叶核加包装器显式状态	16748bit	18906bit	269.75B
新增包数据	256B	512B	256B
实际数据S	16KiB	16KiB	0

没有运行综合面积、STA、P&R或功耗分析；上述位数不是mm²。300MHz是固定评价时钟，不能据此宣称新RTL物理达频。前态完整备份分支task/247-pre-m-area-r2-ed9f5ee6固定第二轮PDF交付ed9f5ee63ceaeb260eb611f10d569ec8904a81c6；大面积候选独立分支task/247-m-k16-area-initial固定a3149d69a23f52efb808dbbb46b5558dffce4df7，两者均创建并读回。

额外初版七文件归档SHA为9150111291360ce468c336549a70c4a4b9b3eb901fa33a4fce302bd0ef1137e2，位于迭代证据backups目录；它保持不可变。正式源码快照另绑定实际测试commit，初版备份不会被后续修复覆盖。

5. 原生RTL实测与数值验证

run20 / Slurm101872 / mdt-r3-finite-m，源码a3149d69a23f52efb808dbbb46b5558dffce4df7，c64/node1/4核，41秒COMPLETED 0:0。两种缓冲各用1:143、2:143、2:144三种初始化/seed，共6次运行。每次66场景、7638检查、20复位点，7477条命令中7458条合法包。使用独立任意精度整数oracle检查每个S96部分和前缀和最终S32舍入结果，包含正负的非饱和RNE中点。

真实16KiB S写入输入并读回最终输出；覆盖K/N尾部、地址、错误命令、同context依赖、8个context、有限队列满、读响应/写ACK/完成背压以及复位。数值、生命周期、有限资源、来源、真实S、控制重放及单/双缓冲公平性七门全部通过。

每个实际RTL周期记录20项输入和27项控制输出。独立控制镜像使用同一输入重放，在valid门控下比较有效地址、标签、提交、完成及资源占用；只忽略最初复位前尚未初始化的一行，后续不跳周期。六次合计299064周期、5157990个有效比较字段通过；翻转有效读地址的负例被拒绝。这是控制重放，数值正确性由前述RTL整数oracle单独提供。

无人为hold的场景	单缓冲：首接受到末DONE	双缓冲：首接受到末DONE	计时边界
单context，K2048	777拍	396拍	包含最终写ACK
单context，K11008	4137拍	2076拍	包含最终写ACK
8 context，K2048	6153拍	3098拍	包含全部完成消费
8 context，K11008	33033拍	16538拍	包含全部完成消费

三seed常态计时一致。由真实请求和响应的FIFO配对推导，读接受到ACK消费、写接受到ACK消费均为2拍单值集合。压力延迟不混入headline，也不取最小值当常态。单context合法下一FIRST可接受时刻比上表末DONE晚1拍；8context场景不额外增加。局部接近两倍的改善不能直接乘到整图token/s。

6. 旧评价体系的具体接入

独立生成器位于project/experiments/iterative_speed/round03。仅static layout0、rows1、A32、W8、shift16、N为8的倍数、总K2048或11008、旧K256 tile使用新服务；每个旧tile对应16个K16包。W16、动态attention、多行prefill和未覆盖尾块保留原路径。资格按格式和形状判断，不按workload名字特判。

保留原DDR请求/64B beat、预取、A驻留/前缀、两A bank引用和两B token、8context调度、每旧tile一次切换、结果DMA、写合并与flush。仅替换完整的本地窗口：删除旧tile输入S聚合预约、adapter/compute/tail服务，改成实测校准的有限控制器。最后tile已内部执行两次S写与ACK，所以删除它的旧p_result_store，避免双重收费。

每次真实读或写真正握手才预约一次S日历；未接受请求不占费用。等待S时，已接受ACK和计算流水仍推进。响应延迟来自实测2拍，响应及完成数量受有限信用约束。每个旧tile排空16个完成并推进到下一接受边沿后才返回，跨旧tile不免费预取；S96 context跨tile保留。入口对齐到核心时钟的不足一拍也计费。

每旧tile输入仍3072B、48次64B服务，但预约从旧聚合变成逐次48个。末输出从旧一次抽象64B服务改为两次16B服务，增加一次预约和一拍S服务；这些差异显式审计。M_tiles仍记旧tile，M_commands改记真实K16命令，M_work计实际core推进、adapter_work计读取；新旧这些累计工作量定义不同，不能拿它们直接算整网加速。

完整S布局在producer生成时检查：A驻留或前缀、两A/两B及旧psum必须位于顶部工作区之前。主配置output为14848到15103，旧512B写合并区为15872到16383，全部落在16KiB中。不能依靠描述符失败或减少覆盖来隐藏容量问题。Calendar删除已过期区间，但保留所有未来预约和当前竞争，不使区间表按历史总请求无限增长。

shared层使用旧统一S日历；idealdual层使用旧分离读写日历，wrapper自身仍不在同拍接受读写。旧DMA仍以原Calendar模型收费，尚未与本包装共享真实响应FIFO。因此整图结果属于条件调度估计，不是完整P/DMA/DDR联合RTL实测，也不验证完整trace的张量数值或真实权重生成。

7. 整图验证与实际性能

run21 / Slurm101878 / mdt-iter3-model，源码010ae8d0d8839967f96b94227d2224fade0edf37，c64/node1/4核，6分06秒COMPLETED 0:0；SystemC3.0.2，81源文件和14输入锁定。24主场景、8个关闭优化的完整RESULT精确回归、8个不适用候选的完整回退通过。五类小trace各在两端口层执行baseline/BUF1/BUF2，共30次，20个候选审计通过。每主case八项篡改，共192项拒绝；六种profile篡改、三非法CLI与缺profile拒绝。原225 kernel、4 validation、5 smoke通过。冻结第二轮九个生成源SHA一致。

下表均为token/s。R3关闭对应第二轮当前最快版本；W16和prefill属于明确回退，不能当新RTL已支持它们。

场景	端口层	R3关闭/R2	R3单缓冲	R3双缓冲
W8 decode512	共享口	3.37834376557	2.19774235407	2.75864978939
W8 decode512	理想1R1W	3.66958239533	3.18560531668	3.66041657326
W16 decode512	共享口	1.88228047460	1.88228047460	1.88228047460
W16 decode512	理想1R1W	2.17900079544	2.17900079544	2.17900079544
W8 decode2048	共享口	2.75828381390	1.91734851443	2.33079926268
W8 decode2048	理想1R1W	2.96156894073	2.63810170368	2.95559639522
W8 prefill2	共享口	3.10725416366	3.10725416366	3.10725416366
W8 prefill2	理想1R1W	3.69669737899	3.69669737899	3.69669737899

主双缓冲理想值比第二轮下降约0.2498%，共享口下降约18.3431%；虽然比本轮单缓冲更快，但不能取代历史最佳配置。每个P有753344个合格旧tile、74008个final输出，转换为12053504个真实K16命令、36160512次读和148016次写，所有ACK/提交/完成与trace独立推导一致。整图不具备原生张量执行和真实生成资格。

原ideal FFN-down为50.63153304ms，双缓冲变为51.31636584ms，是主项退化的主要来源；其余静态shape合计变化很小。共享口还承受生产者S写与逐次输入读的竞争，不能将Calendar等待合计再加到总耗时或忽略它制造收益。更宽乘法资源和较快局部流水并没有消除这些约束。

独立审计重读全部24个结果、20个小trace候选、原日志与来源，并重执行192个篡改检查；RTL侧还独立检查447份回收结果SHA、22源码成员、537192个实际SRAM服务字及其中960个最终输出字。源数值断言、控制镜像和整图调度估计分别陈述，没有把其中一种证据冒充另一种。

run21主结果SHA为bccd917afba10bb9c3f65f62b26b1eab588a85d73c364a4b4d54962b5197afb8，payload SHA为ac5640e807edade9f4984392be6f9074c1ae070b8708c603578a34db871b3eba。156个输出完整哈希，113个选中结果回收核验；原始回收包SHA为c2a8987c0a6b78f43c1aba91aec65c3ea4495f4201168b43ced70cb46892d373。

8. 证据保存与复跑

run20结果SHA为87842b59e42fb0773eedb82dce4981614432868fa12218c3aa15166b0b839eff，payload SHA为df10cfb717b40b4ab4f4d2c4fd48ebff58b260d22a236898bb224e1d9a43c1c6。原始回收包SHA为12f02920509a9379449a425a3dd0d7c8799ce50f0e7fe91a5d6b1fef117e4b42。554个输出在服务器完整哈希；447个选中结果已本地逐文件核验。约312MiB回收包中的62个大日志/控制文件留在获授权项目服务器和本地，仓库retention.json列出路径、字节数和SHA，其余选定证据及全部源/输入快照保存于仓库。

服务器登录yuzelu@10.129.166.172；本人父目录/public/home/yuzelu/Melodydt/issue247-area-speed。每个run的source/、slurm-job.log及results/持久保存。冻结源、输入、工具、实际命令、主结果与回收索引均绑定SHA；后续文档commit不充当实际运行源码版本。

```
sacct -j 101872,101878 -X --format=JobID,State,ExitCode,Elapsed,NodeList
cd /public/home/yuzelu/Melodydt/issue247-area-speed/run21
tail -n 60 slurm-101878.log
cat results/result.json
# 在新目录按归档manifest和job.sh重新提交，不覆盖已有run
```

离线证据核验：python work/Melodydt/247/speed-iterations/verify.py。完整raw不在Git时，此命令检查保留索引与服务器输出哈希的一致性，不声称重新读取了服务器raw；本轮独立审计和本地回收SHA核验另存。管理结构检查python scripts/check_project.py单独运行，不能替代业务验证。服务器EDA仅Slurm分配节点执行，没有本机或登录节点EDA。

9. 本轮取舍与下一轮

第三轮保留为已验证的独立候选和负结果，不替换当前最快的第二轮。最佳主项仍为理想3.66958239533、共享3.37834376557 token/s，未达5；完成本轮PDF后继续第四轮。默认参数和生产P不因候选局部更快而自动切换。

下一轮比较了1KiB A寄存器缓存与NExp四通道。前者可消除FFN-down八context重复读取中的7/8 A读，但不减少权重DDR字节；其固定P总线853770240B，在17.1GB/s下至少49.92808421ms。相对R3该shape只有1.38828163ms的理想改善空间，若其余span不变，整图最高约3.67911；相比第二轮最多约0.26%，还未支付缓存查询、64B复制、实际写snoop和防过期回填控制的成本。这个上限是受限诊断，不是已实现性能。

因此第四轮从第二轮最佳配置出发，仅将新op12的指数通道由2扩到4；普通N指令保留原两通道及周期。NX32的128bit包宽、每包最多四S32容器和真实S/DDR费用保持。预计最多节省少量补充NExp计算时间，不能承诺5；仍需真实RTL周期、状态兼容和旧体系整图验证。1KiB A缓存暂留研究方案，没有实施。四轮上限仍按用户要求执行，不用扩大缓存范围或改变评价条件绕过停止标准。

任务保持in_progress，PR待独立审查、未合并。登记management-hub PR5 pending；缺适用Projects配置/能力，看板unverified、同步pending，管理员与独立审查人待指定。综合面积、时序、物理签核、原生整图生成及GitHub CI分别记录。没有配置聊天结束后的自动监测。