第四轮：仅扩展单命令NExp的计算通道

文档来源 commit：f4be5c50507fec202551e45e39fb2215fc18876c

源文档 SHA-256：32eeabdeab184242c003822ade64533e0a1ef0933e884f8fba5ef307bc9fa058

原文与链接：查看固定版本来源

口径说明：吞吐沿用旧体系的条件估计；RTL功能、局部实测、面积证据与整图条件结果分别报告。

Issue247 / PR243；Melodydt；2026-11-10，Asia/Shanghai。这是本次最多四轮迭代的最后一轮。第三轮矩阵候选没有超过第二轮，因此本轮从第二轮最快配置继续，增加新op12的指数计算并行度。实际校准、旧体系结果和停止判定见后文，所有数字按真实回执填写。

1. 瓶颈研究与方案选择

第二轮主W8 decode512理想端口耗时272.510572667ms，3.66958239533 token/s；共享口3.37834376557。Dot占主理想时间82.2359%。第三轮实现真实四bank、有限包槽和S96控制后，双缓冲理想主项3.66041657326，共享2.75864978939；局部流水改善受输入服务和仲裁抵消，所以本轮没有默认启用更慢的候选。

曾比较1KiB A寄存器缓存。它能减少FFN-down八context间重复A读取，但不能减少权重DDR流量。第三轮该shape51.31636584ms，固定853770240B和17.1GB/s给出49.92808421ms的字节服务诊断；只改此shape且保留其他span时，最乐观主项约3.67911，相对第二轮约0.26%，还未计查询、复制、真实写失效及防过期回填成本。这是范围明确的筛选估计，不是新实现或通用上界。

本轮选择范围更小的NExp四通道。第二轮已经把批处理四命令缩为单op12，但每次CALC仍只算两个元素。主模型的NX32包最多四个S32容器，四个元素需要两次CALC/ACCUM；增加两条指数通道可使该包一次处理完。四通道不改变包宽，也不把八个S32挤进128bit，更不删掉外层S和DDR费用。

评价保持旧PR241/Issue247的300MHz、17.1GB/s、2P/1U、每block 16KiB、ctx8和原trace。主停止项为W8 decode512，共享与理想端口分列；prefill/W16/长上下文仅辅助对照。第四轮完成即满足轮数停止条件，不以更改clock、精度或带宽凑足5。

2. RTL实现方法

只修改生产block_v2_n.sv和pu_u_group.sv，增加NEXP_DIRECT_LANES参数，默认2，仅允许2或4；非法静态配置在启动时报错。U只有NEXP_BATCH和NEXP_DIRECT同时开启才向N传递所选宽度，否则仍传2。已有pu_nexp_shared和nexp_batch_adapter逐字节保持第二轮源码，一个U仍只有一个N。

```
原U op15/NX32 -> 同一S读客户端 -> 同一N所有权
              -> op12 CALC：原两EXP + 可选额外两EXP
              -> ACCUM：写回原128bit结果 -> 同一响应
              -> 同一S写客户端 -> 实际ACK -> DONE
```

新增generate分支仅在有效四通道配置实例化。两个额外指数结果寄存器及valid位在op12的CALC阶段更新，读取position+2与position+3；输入在非op12时关闭。原raw/gamma/square、统计、归一化及EMIT两通道循环完全保持。

ACCUM对op12四通道使用步长4，其余仍步长2。额外有效结果写入原result对应lane；最后一次响应同时直接覆盖当前额外lane，避免非阻塞赋值使rsp_data看到前一拍result。position、128bit结果和响应寄存器复用，不再增加一组外部包缓存。

参数两通道必须与第二轮完整事件和周期一致；四通道但DIRECT关闭也必须保留原四命令批处理时序。四通道启用时普通op0到11的数值、错误、状态和相对完成周期保持；只让无状态op12缩短。这些都是实际测试门，不能只因代码分支看似隔离就认为成立。

3. 数值、状态与面积

四条EXP通道调用同一整数函数和同一查表常量：非负输入编码32768，低于表范围返回0，中间使用原端点选择、插值及舍入规则。没有新截断或近似。NX32仍使用每个S32容器的有符号低16位、结果U16零扩展到S32；已用容器高16位按既有合同忽略，未用容器全零。此合同不等于任意S32指数。

原生op12 count为1到8，param/aux必须为0，未用S16 lane必须为0。外层PACKED16最多八S16、NX32最多四S32；旧模型S16输入/S32输出的prefill依然不合格，完整回退。额外通道不修改maximum/count、factor、exp统计、replay和top持久状态，响应背压、唯一N所有权、S写ACK和全组复位路径保留。

新增显式顺序状态为2×16bit指数结果加2bit有效位，共34bit（4.25B）。组合资源增加两条EXP路径，包括四次同时端点查询、插值算术、舍入和选择布线。单一常量源文件不意味着免费多端口ROM；34bit不能代表总面积。没有复制完整N、除法/开根、统计阵列或SRAM。实际数据S仍16KiB。

综合面积、STA、P&R及功耗未执行，300MHz仍只是固定比较条件。第二轮完整备份task/247-pre-m-area-r2-ed9f5ee6和每次不可变源快照保留，第三轮大面积候选另有独立分支。本轮扩通道候选的额外备份信息在追溯节记录，以便恢复任一资源方案。

4. 服务器RTL验证与周期标定

run22 / Slurm101884 / mdt-r4-nexp-rtl，源码7048c35ed2912e80e62bd7827deaec480d4a7e1a，c64/node1/4核，5分45秒COMPLETED 0:0。21个编译配置依次执行，每个用三种初始化/seed：1:143、2:143、2:144。63次运行中，60次合法配置成功、3次LANES3按指定错误文本拒绝；85条工具命令含82条成功和这3条预期失败，不能放宽为接受任意非零退出。

所有11项门通过：计算/fullU/数值/生命周期、默认兼容、普通指令、持久状态、旧四命令、默认两通道、DIRECT0四通道及实际四通道执行。每个active compute seed有66524个输入值、8588帧，覆盖外层全部65536种S16；原生端经既有clamp实际是32768个负值加0，共32769唯一值，不能称原生65536唯一值。每个fullU有661检查、409次S读和43次S写；stateless有12类状态、102检查及12个复位时点。

旁观测试按每个成功op12响应核对CALC次数等于ceil(count/lanes)，并核对每种count的直方图工作守恒。active compute每seed接受8608条op12，其中8607条完成并通过CALC核对，一条由指定reset终止；累计16810次CALC。完成数与接受数分开，不把reset取消的请求算成完成，也不只在JSON自报四通道。

默认两通道对新运行的精确R2源码比较完整native握手、数据/错误及实际S时间事件；另从run18真实21份日志逐SHA派生observed输入，原COMPAT、S、测量和PASS事件完整复现。DIRECT0四通道保持原四命令，普通N相对响应周期保持。非法lane静态拒绝、错误尾lane、响应/S ACK背压和复位均保留原检查。

NX32元素数	R2计算接受间隔	R4计算接受间隔	R4完整U事务
1、2	7拍	7拍	16拍=5输入+6计算+5输出
3、4	9拍	7拍	16拍=5输入+6计算+5输出
5、6	16拍	14拍	两个真实NX32子包
7、8	18拍	14拍	两个真实NX32子包

三seed实测一致，模型费用为[7,7,7,7,14,14,14,14]。此间隔含计算包装器控制开销；完整U时间另列，不能把它再次加到已经保留的vector_region。没有把PACKED16八元素费用用于八个S32。

独立审计检查63份原始运行日志、106项本地输出SHA、36源码和2输入，重新用整数查表规则计算601560个实际原生完成元素；从连续实际CMD边沿复核计算间隔。fullU还核真实S最近写入到读值及1RW访问约束。raw handshake trace不含reset边标记，复位证明明确依赖冻结程序与实际PASS，不冒称独立重建完整复位波形。

5. 原评价体系接入

第四轮模型从第二轮实际run19作为关闭基线，第三轮矩阵路径不启用。独立round04生成器保留R1/R2冻结源和全部旧trace、cache、S、DDR、E及矩阵费用，只替换NExp在原vector_region之后的补充计算服务。新费用只能来自通过门的实际四通道NX32接受至下一接受间隔。

新profile绑定真实native/U/router/adapter/EXP五个精确源码SHA、命令退出码、日志、三seed、完整U及持久状态证明。逐条op12的CALC次数必须符合ceil(count/4)，不能仅在JSON写lanes4而实际仍跑两通道。n5到8仍按两个真实NX32子包相加，禁止使用PACKED16的八元素时间替代。

关闭优化或没有合格操作时，移除唯一新增iteration4_study字段后完整RESULT等于run19。启用时common计算账本绑定新profile，原第二轮账本完整保留为iteration2_baseline_study，明确它是反事实比较，避免把旧费用标成当前费用。R4 metadata独立列旧费、新费、实际收费和差额。

所有DDR逻辑/总线字节、描述符、M工作、S预约、cache和非NExp向量工作均逐项守恒。变化只能体现在补充计算及其串行端到端时间。结果篡改、缺profile、假lane2冒充4和来源不匹配必须拒绝；旧kernel/validation/smoke也用实际生成binary执行。

6. 实际性能与四轮比较

run23 / Slurm101888 / mdt-iter4-model，模型源码e6209544086f2460662bf7edfc91cbfb2c63cd9b，c64/node1/4核，00:02:55，COMPLETED 0:0。77源和14输入SHA绑定，SystemC3.0.2。16个主场景、8个关闭优化完整RESULT回归、2个prefill完整回退通过；每case八种结果篡改共128项拒绝，profile篡改、三非法CLI、R2关闭和缺profile均拒绝；原225 kernel、4 validation、5 smoke通过。冻结R2九个生成源SHA一致，独立结果和日志审计通过。

场景	端口层	第二轮最佳	第四轮	相对变化
W8 decode512	共享口	3.37834376557	3.38396291561	+0.16633%
W8 decode512	理想1R1W	3.66958239533	3.67621308212	+0.18069%
W16 decode512	共享口	1.88228047460	1.88402353266	+0.09260%
W16 decode512	理想1R1W	2.17900079544	2.18133705644	+0.10722%
W8 decode2048	共享口	2.75828381390	2.77332356601	+0.54526%
W8 decode2048	理想1R1W	2.96156894073	2.97891420928	+0.58568%
W8 prefill2	共享口	3.10725416366	3.10725416366	+0.00000%
W8 prefill2	理想1R1W	3.69669737899	3.69669737899	+0.00000%

单位token/s，均为旧体系条件估计。主ideal本轮减少0.49152ms，即147456个300MHz周期；这来自73728个NX32 n4包各减少两拍。主补充NExp从663552拍降为516096拍；长context2048减少1.96608ms。M、DDR、S和非NExp工作守恒，不能将局部9到7拍比率直接乘到整网速度。

四轮主项结果如下。第三轮数值是该轮双缓冲候选本身，因低于第二轮而没有作为第四轮基础。每轮结束的最佳值都允许保留之前版本。

版本/轮次	共享口候选	理想端口候选	是否采用
本次迭代起点	3.23081074122	3.49616888299	比较基线
第一轮：单N批处理	3.35052563236	3.63678454238	是
第二轮：无状态单op12	3.37834376557	3.66958239533	是
第三轮：矩阵有限双缓冲	2.75864978939	3.66041657326	否，独立保留
第四轮：op12四EXP通道	3.38396291561	3.67621308212	是，可选参数

最终主项最佳ideal 3.67621308212，shared 3.38396291561；相比迭代起点分别增加5.1498%和4.7404%。未达到5 token/s，但已完成四轮研究、方案、RTL及评估；第四轮PDF完成后按用户的轮数上限停止，不开展第五轮。

这不是当前四1RW宏上完整原生LLM生成实测。理想端口仍是条件层；共享口也保留旧模型的接口/费用抽象。生产可选优化需NEXP_BATCH=1、NEXP_DIRECT=1、NEXP_DIRECT_LANES=4；默认值为兼容路径，不将可选参数误称默认已经启用。第三轮大矩阵候选没有替换生产P。

7. 追溯、复跑与交付状态

第四轮扩通道独立备份task/247-nexp4-area-r4固定7048c35ed2912e80e62bd7827deaec480d4a7e1a，已创建读回。第二轮基线及第三轮大面积分支继续保留。服务器登录yuzelu@10.129.166.172；本人/public/home/yuzelu/Melodydt/issue247-area-speed/run22和run23，各自source/、slurm-job.log及results/持久保存。

证据	SHA-256
run22 payload	bef21863b43f329e9adf18be7e7a52b096f02a4700d01ff2c94231d1a3cb999d
run22 result	5abb31227f0c7b2c7ac9ff7eb8f80687569fab0b64bf74eb1a9ea6ccb54b518d
run23 payload	9e581f0e41eaf5926c892edb596d46aeac692b9b41319bc7f14390a715881e76
run23 result	52c5faaad4d67a30577a5b4bc6d564866627105d492ea37aabc31d5b5b5372ff

run22全部1122输出哈希，106份选中结果本地核验，1016个编译对象/二进制留服务器。原回收包63447040B、SHA5105067aeabe69441592d24f491a43f3d3ec7602ba8870678830b40a7b8a3221；其中30个大raw由retention索引明确保留在服务器和本地归档，仓库保存剩余证据与精确SHA，不冒称Git含全部原始内容。run23全部101输出哈希、71选中结果回收核验，归档SHA422af4cb3430c9f189e11753a862ea167ef264ae4177b50b9bd87583af3e9b96。

```
sacct -j 101884,101888 -X --format=JobID,State,ExitCode,Elapsed,NodeList
tail -n 60 /public/home/yuzelu/Melodydt/issue247-area-speed/run23/slurm-101888.log
cat /public/home/yuzelu/Melodydt/issue247-area-speed/run23/results/result.json
# 复跑用新目录，按已归档输入/源SHA与job.sh提交；不覆盖run22/23
```

源码运行commit与报告/PDF commit分别记录；后续文档head不冒充已运行源码。离线python work/Melodydt/247/speed-iterations/verify.py核验各自冻结源、输入和结果；只有显式--current-run才核对当前文件，不能修改旧SHA使历史资格转移。python scripts/check_project.py仅检查管理结构。所有EDA/SystemC在Slurm分配节点运行，没有本机或登录节点仿真。

本次迭代交付后进入待独立审查阶段，PR未自行合并，Issue不标done。登记management-hub PR5 pending；缺Projects配置/能力，看板unverified、同步pending。管理员和正式审查人待指定；GitHub CI状态按最终远端回执记录。完整原生大模型生成、量化质量、面积和物理时钟仍需独立验收。本次不新增第五轮，没有配置聊天结束后的自动监测。