U 有限队列与 NExp 区域接入：实施及评估

文档来源 commit：51661c100a68c43f2673424c758d6ddf4c20fdb3

源文档 SHA-256：5cdad06b3b5fefe7b684ecb9ae1d3f945946856d62eea00a40b74cc04ef332a3

原文与链接：查看固定版本来源

口径说明：吞吐沿用旧体系的条件估计；RTL功能、局部实测、面积证据与整图条件结果分别报告。

2026-11-11，Asia/Shanghai；负责人 Melodydt；Issue247 / PR243。本轮落实上一轮的 U 供数重叠建议，保持共享池 32KiB、原 S 端口和外存带宽。生产功能为可选实现，提交待审查，尚未合并。

1. 结论与证据层级

已实现 2/4 槽有限 E 指令队列，以及将连续 NExp 区域拆成真实 U 描述符的控制器。完整 U 微基准中，两槽将 64 条一元指令从 960 拍降到 578 拍，四槽降到 516 拍；这是真实 RTL 周期改善。NExp 的 22016 值相同构造输入，S32 容器路径 94256 拍、S16 路径 63984 拍，吞吐提高 47.31%。

推荐先采用两槽作为后续集成配置，E_QUEUE_DEPTH 的默认值仍为 0。两槽前端比旧前端增加 0.00691334 mm² 标准单元；四槽增加 0.01587754 mm²。两槽已取得主要收益，四槽对三输入指令无额外改善；这两种选择均未增加 SRAM 宏。

原图纯 S16 E 算子的直接可映射数量为 0，因此不能将微基准倍率乘到全部 S32 向量工作量。新模型只把已经测通的 S16 NExp 区域费用替换为实测 U 服务期。三种队列深度的整图条件结果相同；这表示尚未获得可核验的整图 E 加速收益，并非队列本身无效。

本轮 195 个原生运行、27 对默认路径完整观测、6 项同库面积、40 个 SystemC 场景、16 个完整历史控制及 200 个篡改负控通过；356 份回收文件 SHA 复核通过。整模型 RTL token/s、真实权重/激活推理质量、全 U 面积及 300MHz 物理时序仍未验证。

2. 为什么要改：串行服务限制了计算流水

上一轮 E 核心已经能够在连续合法输入时 II=1，但完整 U 的单命令服务依次读 S、喂 E、等待结果、写 S、等待 ACK，再收下一条指令。仅替换核心时，完整 U 自然参数测试 988 到 984 拍，收益仅 0.4065%。

现有 local-S arbiter 只接受一条未完成存储事务，按 IDLE、SEND、RETURN 服务。128bit 数据宽度并不等于每拍可完成一个 16B 请求。队列能够用后继指令的读取填补 E 执行空档，却无法越过这个事务吞吐上限。本轮二/四槽测试保留同一 SRAM、仲裁器和计算核，没有引入理想双端口。

3. RTL 方案与具体做法

3.1 有限队列

新增 `pu_queued_e_service.sv`，由 `pu_u_group.sv` 的 E_QUEUE_DEPTH=2 或 4 选择；0 保留原串行前端。E_PIPELINE 仍独立可选。每槽保存 opcode、shift、源/目标地址、store/direct 标志、三个 128bit 操作数、128bit 结果、错误/饱和位和进度。

槽位状态为 FREE、READING、READY、EXECUTING、RESULT、DONE。环形 head/tail/count 管理容量；读入、核心执行和老指令写回可以跨槽重叠。读取和核心发射保持指令顺序，结果对应最老执行槽，写回及完成严格按 head 提交。单 S 客户端仍最多一条事务，写回优先。

RAW 检查读地址是否匹配更老且尚未写 ACK 的目标地址；只在 ACK 后解除。按序读取、按序写回同时保持 WAR/WAW。done 背压会占住槽位，队列满时 cmd_ready 拉低；不会用理想无限队列隐藏等待。缺失操作数清零，超过算子真实元数的源仍按旧协议读取但不喂成下一条指令。

direct-A 支持输入背压和 abort；错误指令不写 S。reset 清除控制和在途状态，但已经完成的存储写入不回滚。N/IO 与 E 的跨客户端数据相关性仍要求调用者同步，本轮未新增跨客户端一致性协议。

3.2 连续 NExp 区域

新增 `pu_nexp_region.sv`。调用者把连续输入分块放入本地 S，明确声明 signed Q5.10 尺度，然后给出元素数、输入/输出基址和输入格式。控制器将 NX16 拆为每描述符最多 8 值、NX32 拆为最多 4 值，通过实际 U N 接口执行；NX16 输出每满帧占两个 S32 结果字。

控制器接受 1..2048 值，提前拒绝零长度、过长、范围越界、输入/输出交叠和未声明尺度，非法区域不访问 S。尾块计数进入描述符，成功计数只在真实 U 完成后递增；出现下游错误立即结束，不伪报完成值。NX32 的旧 ABI 要求未使用尾容器清零；NX16 可以屏蔽脏尾部。

这一级负责已经暂存的区域，不负责 DDR DMA、图张量分配、自动量化或整个模型调度。数值来自独立整数/Decimal oracle 生成的 Q5.10 样本，输入输出按位比较。原 trace 提供形状和位宽，没有完整激活值及量化尺度，不能将本验证描述为真实模型数值推理。

3.3 兼容和面积取舍

默认配置与冻结的旧 U 前端比较，9 组负载各 3 个时序/seed，共 27 对观测完全一致。备份分支 `task/247-before-u-queue` 固定在 63089fb910d26ce37ae31a14dd4ef39c80c4ca6a，已读回核验。新增模块不改变共享 SRAM 容量，不扩宽全局入口，也不改变 P 的 M 核或 DDR。

4. 原生周期、覆盖及失败修正

下表使用相同工作、同一 S 后端、E_PIPELINE=0。前四项各 64 条指令，其余混合/相关/争用负载的完整计数见证据；不可把不同负载的周期横向当作同工作比较。

负载	旧串行/0槽	2槽	4槽
unary_s16	960	578	516
binary_s16	1280	834	772
ternary_s16	1600	1033	1033
narrow_s32	960	578	516
mixed_edges	1954	1296	1181
hazards	2922	2363	2362
direct	2212	1321	1149
backpressure	1341	916	772
io_contention	2114	2114	2114

一元吞吐两槽 +66.09%、四槽 +86.05%；二元两槽 +53.48%、四槽 +65.80%；三元两种队列均 +54.89%。相同四类内存供数负载下，E_PIPELINE=0/1 的周期相同，说明本测试首先受供数协议约束。四槽一元 128 次 S 访问用 516 拍，约 4.03 拍/访问；它是完整服务的观测比例，不是 SRAM 宏自身的延迟定义。IO 争用例三种深度均为 2114 拍，表明其他客户端占用 S 时，增加队列不能创造额外端口带宽。

测试覆盖全部 16 个 opcode、独立算术 oracle、source_count 0..3、饱和/非法值、RAW/WAR/WAW、别名、direct/abort、done 背压、其他 IO 客户端争用和三个 reset 时点。每配置 9 例 × 3 运行；旧参考及六种候选配置共 189 运行。NExp 两种格式各 3 次，覆盖 1..17、63、64、65、2048 值、六类非法区域、异常 payload、reset 及完整 22016 值形状，共 6 运行。

NExp 同输入比较	S32 容器	packed S16
22016 值 / 344 个 tile 周期和	94256	63984
64 值 tile 起始接受到完成（含首尾拍）	274	186
模型采用服务期（另加 1 拍完成退休）	275	187
S 读 / S 写	5504 / 5504	2752 / 5504
U 描述符数	5504	2752

这组周期排除测试台装载、输出检查和主动延长的完成背压；模型仍通过 cache/DDR 保留输入和输出交通。原 prefill 图有 36 个相同 22016 值 NExp 形状；原生验证完整执行一个唯一形状的构造数据，并非运行 36 组真实激活。

首轮 run44/job102083 在 189 个队列运行通过后，因 NX32 正例的未使用尾容器被填 1 而失败。修正测试为旧 ABI 要求的零尾，并新增坏 payload 错误传播测试；未删除有效检查。run45/job102084 全量重跑通过。失败回执、原目录和 SHA 保留，未覆盖。

5. 沿用原评价体系的 token/s

固定 300MHz 条件频率、2P/1U、共享 32KiB、A32B/拍、DDR17.1GB/s，四工作负载各 shared/idealdual。idealdual 继续表示原模型的理想双端口服务场景，不能据此宣称全部实际 S/DMA/U/互连满足该条件。本轮 U 区域费用在两种场景均采用同一真实单事务后端实测期。

下表每格为 shared / idealdual，单位 token/s。基线和上轮 S16 局部校准均重新运行并与冻结历史完整 RESULT 一致；最后一列为本轮局部区域实测校准后的条件模型。

场景	原基线复现	上轮 S16 局部校准复现	本轮 U 区域校准
W8 decode512	3.449322 / 3.700221	3.449322 / 3.700221	3.449322 / 3.700221
W16 decode512	1.932379 / 2.192427	1.932379 / 2.192427	1.932379 / 2.192427
W8 decode2048	2.817071 / 2.994659	2.817071 / 2.994659	2.817071 / 2.994659
W8 prefill2	3.894197 / 4.398913	4.216864 / 4.815109	4.184811 / 4.773362

region_q0、region_q2、region_q4 三种结果完全一致，并检查 16 对等价性：三个 trace 中纯 S16 E 的直接可映射算子数均为 0，S32→S16 Convert 的存在也不足以证明全部中间量可量化为 S16。未实现的 E 映射不给额外加速信用。原有 S32、canonical、M、cache、DDR 条件模型继续保留。

替换规则：对可匹配的每个 64 值 S16→S32 NExp tile，保留原 cache touch/失效/回写；删除旧 E 向量费、NExp 补充费和本地 S 读写费，改为一次 187 拍 U 服务预留。U 服务已经包含序列器、N 核、S 请求和 ACK；不再重复 cycles()/sio()。图级向量工作守恒与流量、M 工作量、cache 事件、有限 DDR 32 credits、共享池峰值和生命周期逐项检查。

prefill 共 36 个区域、12384 个 tile；移除向量费 260064 拍、上轮 NExp 费 891648 拍，新增实测区域费 2315808 拍。本地 S 旧服务另行移除，精确 subcycle 数见模型 ledger。区域校准比仅用算术核局部费用更完整，数值下降不应解释为 RTL 变慢。

上轮 4.815109 是 S16 局部费用校准条件值；5.112600 还额外假设完整 U8 服务，至今不是已实现的整图速度。本轮不能据微基准提前宣布达到 5 token/s。

6. 面积评估

使用同一 Nangate45 库、Yosys 0.63 / ABC 流程；Verilator 5.042、g++11.4.0；工具/库/配置 SHA 在证据中。面积是映射后的标准单元，不是芯片布局面积；未包含 SRAM 宏、S 仲裁、N 核、U 胶合连接、时钟树和布线。

映射模块	面积 μm²	用途
原串行 E 前端	2473.002	比较基准
两槽 E 前端	9386.342	主要推荐配置
四槽 E 前端	18350.542	面积换剩余独立指令收益
原 E 核	56905.380	保持旧算术
可选 E 流水核	59758.230	上轮可选实现
NExp 区域序列器	882.056	本轮新增控制

两槽前端增量占“旧前端 + 旧 E 核” 11.64%，四槽为 26.74%。加上新序列器，本轮两槽增量 0.007795396 mm²、四槽 0.016759596 mm²；新增 SRAM 宏为 0。该比例不能当作全 U 或全芯片面积涨幅。

两槽到四槽前端接近翻倍，一元仅再提升 12.02%、二元 8.03%、三元 0%。默认仍关闭；建议在完成原图位宽映射后优先启用两槽，再按真实依赖图决定四槽。E 流水是否有物理频率优势需要 STA，不能由本周期测试判断。

7. 下一步优先级

第一，落实原图 S32 向量语义。优先定义原生 S32 E 子集与数值/饱和/shift 合同，或提供经过真实量化校准的 S16 映射；不能直接把 S32 截短。先选占时大的可复现算子区域，验证依赖链与真实 S 交通，再将队列实测纳入 token/s。

第二，在两槽配置上测本地 S 仲裁的连续请求能力。研究有限请求/响应队列或明确的 1R1W 服务，保留 read-after-write、跨客户端顺序及 reset 合同；新服务必须实际通过 U 回归并同库综合，再决定是否扩宽。单纯增加槽数无法消除本轮约四拍一事务的瓶颈。

第三，补齐 NExp 真正图级部署需要的激活值和量化尺度，接入 DDR 暂存/输出消费及完整模型调度。共享 SRAM 保持 32KiB；48/96KiB、更多 M 和更高带宽仍作为单独条件研究，不在本轮混入硬件收益。

8. 复现、版本与交付

运行	源码 commit	Slurm / 结果
run44 失败记录	f264095284e1c6e940270c3027b7133794dd22fa	102083，1:01，FAILED 1:0
run45 原生 + 面积	0109de8555cda51ee73498f9966df69cb550ba19	102084，1:52，COMPLETED 0:0
run46 原体系模型	e6b2c31f1a593ee9393be0088f90c9d762622e94	102092，见 sacct.txt，COMPLETED 0:0

全部作业登录目标 yuzelu@10.129.166.172，目录 /public/home/yuzelu/Melodydt/issue247-area-speed/run45 或 run46，c64/node1/4核。代码位于各目录 source/，实际提交在运行根目录执行 sbatch --parsable job.sh；脚本用 srun、Singularity 容器和锁定工具。原始日志/构建/网表留服务器，以 output-files.sha256 索引；仓库提交有界回执，不上传大体积原始物理数据。

```
cd /public/home/yuzelu/Melodydt/issue247-area-speed/run46
squeue -j 102092
sacct -j 102092 -X --format=JobID,State,ExitCode,Elapsed,NodeList
tail -n 30 slurm-102092.log
cat results/result.json
```

原生启动入口 project/experiments/u_queue_native/run.py；模型入口 project/experiments/u_queue_model/run.py；分析入口同目录 analyze.py。模型冻结 run42 生成源码及完整结果 SHA，并绑定 run45 的实际校准 RTL SHA；每次另建运行目录，不能覆盖已完成 results。

原生 result SHA：4c006aa78b73a18bcdc90e7155c8995d2780ab38bfc6e3bd310c44d8ecd3c960。模型 result SHA：4be10c512c8d28e7e41eaaedab4a4f6803adbc4450458f0ec59f33c49b20c1cc。完整源/输入/输出 SHA、运行命令、oracle 配置和工具版本见证据索引及分析。

管理结构检查 python scripts/check_project.py 已通过，仅证明管理结构。GitHub 源码 CI42858846633 completed/failure，validate 无 steps/logs，原因待管理员核实；未绕过检查。正式审查人待指定，PR 尚未合并；本轮交付 in_review，不记 done。登记 management-hub PR5 仍 open/unmerged，pending；无 board 配置及 Projects 工具，看板状态 unverified、同步 pending，管理员待指定。工作遵守 rayggxia-project-collab 1.0.0。全部本轮作业结束，无自动监测；恢复从交接开始。